Analyse de la prédiction du churn dans le secteur de l'énergie

Structuration et interprétation du projet prédictif

Contexte et objectifs du projet

L'entreprise évolue dans un environnement énergétique très concurrentiel où la fidélisation des clients constitue un enjeu stratégique majeur. La résiliation des contrats, ou churn, engendre des coûts significatifs, tant directs qu'indirects, incluant la perte de revenus, les dépenses liées à l'acquisition de nouveaux clients et l'impact sur la stabilité opérationnelle. Face à ces enjeux, le projet vise à concevoir un modèle prédictif fiable afin d'identifier les clients susceptibles de quitter l'entreprise. Cette démarche permet de cibler les actions de rétention et d'optimiser les efforts des équipes commerciales.

Présentation du dataset

Le jeu de données utilisé comporte 2 000 clients et intègre cinq variables, toutes complètes, facilitant ainsi l'analyse. Les informations recueillies sont essentielles pour décrypter les comportements des clients :

- **Âge :** âge du client
- **AncienneteMois :** durée de la relation avec l'entreprise en mois
- **ConsommationAnnuelle :** consommation énergétique annuelle
- **FacturesImpayeDernierAn :** nombre d'impayés constatés sur les 12 derniers mois
- **Churn :** variable cible indiquant le départ (1) ou la fidélisation (0)

La présence de la variable cible *Churn* permet de modéliser précisément la probabilité de départ et d'identifier les segments de clientèle les plus sensibles. Le dataset est propre, complet et directement exploitable pour une analyse descriptive ou prédictive orientée vers la rétention.

Répartition du churn

L'analyse de la répartition du churn révèle que 1 200 clients, soit 60 %, restent fidèles à l'entreprise, tandis que 800 clients, correspondant à 40 %, ont résilié leur contrat. Cette proportion significative de churn justifie pleinement le recours à une approche prédictive afin d'anticiper les départs et d'orienter les actions de fidélisation.

Analyse exploratoire des données (EDA)

Âge

La moyenne d'âge des clients est de 49,6 ans, avec une forte dispersion. La clientèle est donc très variée, allant de jeunes adultes à des seniors, ce qui peut influencer les comportements de résiliation et de fidélisation.

Ancienneté

L'ancienneté moyenne s'établit à 60 mois, mais les valeurs observées varient de 1 à 120 mois. Deux segments distincts se dégagent : les clients récents, généralement plus volatils, et les clients fidèles, qui présentent une plus grande stabilité.

Consommation annuelle

La consommation énergétique annuelle moyenne est de 8 085 kWh, avec une amplitude importante. Les gros consommateurs constituent un segment stratégique pour l'entreprise, notamment en termes de revenus.

Impayés

75 % des clients n'ont connu aucun impayé sur la dernière année, mais une minorité a accumulé jusqu'à six impayés. Ces impayés sont un signal fort de risque de churn et doivent être surveillés attentivement.

Modélisation et performances

Le modèle retenu pour la prédiction est un *RandomForestClassifier*, reconnu pour sa robustesse et ses performances sur des données tabulaires.

Résultats obtenus

- **Accuracy :** 96 %
- **Précision :** 91 %
- **Recall :** 99 %
- **F1-Score :** 95 %

Interprétation

Le recall très élevé démontre que le modèle parvient à détecter la quasi-totalité des churners, ce qui est essentiel pour maximiser la rétention. La précision élevée permet de limiter les fausses alertes et le F1-Score atteste d'un excellent équilibre global. Ainsi, le modèle se distingue par sa fiabilité et sa stabilité, le rendant parfaitement adapté à une utilisation opérationnelle.

Visualisation des performances

Un graphique en barres a été réalisé pour comparer les quatre principales métriques du modèle, facilitant ainsi l'interprétation des résultats pour les équipes métier. Cette visualisation met en lumière la capacité du modèle à identifier efficacement les clients à risque.

Exploitation métier et recommandations

Grâce au modèle prédictif, il est possible d'identifier précisément les clients susceptibles de résilier leur contrat. Les équipes CRM peuvent alors utiliser ces scores pour prioriser les actions de rétention, telles que des offres personnalisées, des appels proactifs ou des remises ciblées. Une attention particulière doit être portée aux clients avec impayés ou présentant une faible ancienneté, car ils constituent les profils les plus à risque.

L'intégration du modèle dans les outils internes, comme le CRM ou les tableaux de bord Power BI, permettra un suivi continu du risque de churn et une réactivité accrue des équipes.

Génération de scores pour de nouveaux clients

Un script a été développé pour charger de nouveaux clients, prédire leur probabilité de churn et enregistrer les résultats dans un fichier Excel propre et exploitable. Ce fichier peut être utilisé directement par les équipes opérationnelles pour mettre en œuvre les actions de rétention adaptées.

Conclusion générale

Ce projet démontre la capacité à transformer les données clients en un outil prédictif à forte valeur ajoutée. Le modèle RandomForest offre des performances remarquables, notamment pour la détection des churners. L'intégration de cette solution dans les processus métier permettra d'améliorer significativement la rétention et d'optimiser les efforts commerciaux.

