Prédiction du churn dans le secteur de l'énergie

Structuration des notes et synthèse du projet

1. Contexte stratégique

Le marché de l'énergie fait face à une intensification de la concurrence, une volatilité croissante des clients et une pression réglementaire accrue. Dans ce contexte, la capacité à anticiper le churn s'impose comme un levier majeur de performance. L'objectif du projet est de concevoir un modèle prédictif permettant d'identifier les clients à risque afin d'optimiser les actions de rétention et de limiter les pertes de revenus.

2. Description du dataset

Le dataset utilisé comporte 2 000 clients et cinq variables clés, toutes complètes. Il couvre les aspects essentiels du comportement client :

- **Profil** : âge du client.
- **Engagement** : ancienneté en mois.
- **Usage** : consommation annuelle d'énergie.
- **Risque financier** : nombre d'impayés sur l'année.
- **Cible** : churn (0 = reste, 1 = part).

La répartition du churn est de 60 % non-churn et 40 % churn, révélant un enjeu significatif pour l'entreprise.

3. Analyse exploratoire

L'analyse exploratoire met en évidence plusieurs signaux structurants :

- **Âge** : population hétérogène (18 à 80 ans), suggérant des comportements variés selon les segments.
- **Ancienneté** : forte dispersion (1 à 120 mois), révélant des clients récents plus volatils tandis que les clients fidèles sont plus stables.
- **Consommation** : amplitude importante, les gros consommateurs représentant un segment stratégique.
- **Impayés** : majorité sans impayés, mais une minorité à risque élevé (jusqu'à 6 impayés).

Ces éléments confirment la pertinence d'un modèle prédictif pour capter les signaux faibles.

4. Modélisation et performances

Le modèle RandomForest a été choisi pour sa robustesse et sa capacité à gérer des interactions non linéaires.

Résultats clés

- **Accuracy** : 96 %
- **Précision** : 91 %
- **Recall** : 99 %
- **F1-Score** : 95 %

Le recall très élevé assure une détection quasi exhaustive des churners. La précision solide permet de limiter les actions inutiles sur des clients non concernés. Le F1-Score élevé confirme l'équilibre global du modèle. Ce modèle est opérationnel et fiable pour un déploiement métier.

5. Exploitation métier

L'intégration du modèle dans les processus CRM permet :

- d'identifier les clients à risque avec un haut niveau de confiance ;
- de prioriser les actions de rétention (offres ciblées, appels proactifs, accompagnement personnalisé) ;
- de réduire les pertes de revenus liées au churn ;
- d'améliorer la segmentation et la connaissance client.

Les variables d'impayés et d'ancienneté constituent des leviers d'action immédiats pour les équipes commerciales.

6. Génération des scores pour nouveaux clients

Un pipeline opérationnel permet de charger de nouveaux clients, prédire leur probabilité de churn et exporter les résultats dans un fichier Excel exploitable par les équipes métier. Ce dispositif facilite l'intégration du modèle dans les workflows existants.

7. Conclusion

Le projet démontre la capacité à transformer des données clients en un outil prédictif à forte valeur ajoutée. Le modèle RandomForest offre une performance remarquable et constitue un support stratégique pour la rétention. L'intégration des scores dans les outils internes permettra d'optimiser les campagnes, de réduire le churn et de renforcer la compétitivité de l'entreprise.

